

BÀI TẬP LỚN MÔN HỌC

Nền tảng lập trình cho phân tích và trực quan dữ liệu

Giảng viên: Lê Thành Sách

Lịch sử phiên bản (Version History)

Version	Release Date	Update Summary
v1.0	03 Nov 2025	Initial release for Semester 1, Academic Year 2025–2026.
v3.0	04 Sep 2026	Updated for Semester 261, Academic Year 2026–2027.

Note: The latest version will be available on the course LMS.

1 Mục tiêu

Bài tập lớn nhằm giúp sinh viên:

- Vận dụng kiến thức về lập trình Python, hướng đối tượng (OOP) và các thư viện phổ biến: **NumPy**, **Pandas**, **Matplotlib**, **Seaborn**, **OpenCV**, **Scikit-learn**.
- Áp dụng quy trình hoàn chỉnh của phân tích dữ liệu: thu thập, tiền xử lý, **EDA (Exploratory Data Analysis)**, trực quan hóa và huấn luyện mô hình học máy.
- Làm quen với nhiều loại dữ liệu khác nhau: **Tabular**, **Text**, **Image**, **Multimodal**, **Time series**.

2 Mẫu tham khảo (Samples)

Sinh viên được khuyến khích tham khảo các ví dụ sẵn có trên GitHub của giảng viên, minh họa toàn bộ quy trình từ phân tích dữ liệu, trực quan đến mô hình học máy.

[Exploratory Data Analysis \(EDA\)](#)
[Machine Learning](#)
[Text Classification](#)
[Image Classification](#)

Sinh viên nên dựa theo cấu trúc và tinh thần của các ví dụ này để hoàn thiện bài tập lớn.

3 Chia nhóm và lựa chọn tập dữ liệu

Quy định chung

Sinh viên có thể làm **cá nhân** hoặc **theo nhóm 2–3 người**. Đăng ký nhóm tại đường dẫn sau:

Group and Dataset Registration Sheet

Mỗi nhóm cần lựa chọn tập dữ liệu theo các ràng buộc nêu ở phần sau và điền thông tin đầy đủ trong bảng đăng ký.

Khối lượng theo quy mô nhóm

- **Sinh viên cá nhân:** thực hiện **2** loại dữ liệu
 - 1 bài bắt buộc: **Tabular**.
 - 1 bài tự chọn: **Text**, **Image**, **Multimodal** hoặc **Time series**.
- **Nhóm 2–3 người:** thực hiện **3** loại dữ liệu
 - Bắt buộc 1 bài về **Tabular**.
 - Bắt buộc 1 bài về **Text**.
 - 1 bài tự chọn trong **Image**, **Multimodal** hoặc **Time series**.
- Khuyến khích sử dụng các mô hình cơ bản của **Scikit-learn**. Nếu áp dụng **học sâu (Deep Learning)**, sinh viên có thể:
 - Tham khảo code mẫu trong các liên kết GitHub ở trên.
 - Xem các phần trích đặc trưng hoặc huấn luyện như các *hàm sẵn có*, không cần tìm hiểu chi tiết kiến trúc bên trong.

4 Ràng buộc đối với tập dữ liệu

Nguyên tắc chung

- Các nhóm nên hạn chế chọn trùng tập dữ liệu. Nếu trùng, các nhóm sẽ được chấm song song và so sánh độ sáng tạo, khác biệt trong cách tiếp cận.

Dữ liệu bảng (Tabular)

- Có ít nhất **2000 samples** và tối thiểu **10 cột**.
- Dữ liệu cần có *missing values* để thực hành thống kê và xử lý thiếu dữ liệu.
- Bao gồm các cột *categorical* để áp dụng kỹ thuật **encoding**.
- Bao gồm các cột *numerical* để áp dụng kỹ thuật **scaling**.
- Ưu tiên các tập dữ liệu có độ khó cao: *imbalanced data*, *outliers*, ...

Dữ liệu văn bản (Text)

- Có ít nhất **2000 samples**.
- Với sinh viên Việt Nam, khuyến khích sử dụng tập dữ liệu tiếng Việt.
- Sinh viên tự thu thập dữ liệu (crawling) để tạo tập riêng sẽ được đánh giá cao.

Dữ liệu ảnh (Image) — yêu cầu chi tiết

- **Quy mô:** tối thiểu **5000 ảnh** (tổng), ít nhất **3 lớp** (đối với classification).
- **Độ phân giải:** khuyến nghị ảnh có cạnh ngắn ≥ 128 px; nếu nhỏ hơn, cần nêu rõ lý do và cách xử lý (resize, padding).
- **Tập dữ liệu:** *KHÔNG chấp nhận* toy datasets (ví dụ: **MNIST**, **Fashion-MNIST**, **CIFAR-10**) cho **bài chính**. Các tập này chỉ dùng để *minh họa pipeline* (không tính là dataset chính).
- **Pretrained bắt buộc (nếu dùng DL):** sử dụng mô hình pretrained (ví dụ *ResNet50*, *MobileNetV3*, *ViT-B/16*) theo một trong các cách:
 - **Feature extractor:** freeze backbone, trích đặc trưng $\rightarrow$ huấn luyện classifier nông.
 - **Fine-tuning nhẹ:** unfreeze một vài tầng cuối, learning rate nhỏ.

Sinh viên có thể coi mô hình như *hàm sẵn dùng*; không yêu cầu hiểu chi tiết kiến trúc bên trong.

- **Split:** nêu rõ cách chia **train/val/test**; tránh rò rỉ dữ liệu (data leakage).
- **Augmentation:** áp dụng hợp lý (horizontal flip, random crop/resize, color jitter, normalization...) và giải thích mục tiêu.
- **Bài toán mở rộng:** nếu làm *detection*, *segmentation*, *pose estimation*, *action recognition*, *re-identification*, *crowd counting*, *depth estimation*, hoặc *3D reconstruction*, yêu cầu:
 - Dữ liệu cần có **annotation định dạng chuẩn hoặc tự thiết kế hợp lý**, có thể sử dụng các chuẩn phổ biến như:
 - * **COCO**, **VOC**, **YOLO**, **LabelMe**, **Cityscapes**, **KITTI**, **MPII**, **Open-Images**, hoặc định dạng **JSON/CSV/XML** tự thiết kế miễn hợp lý.
 - Nếu tự gán nhãn, cần mô tả công cụ sử dụng (VD: LabelImg, CVAT, Roboflow, VGG Annotator...) và cách đảm bảo chất lượng nhãn.
 - Báo cáo cần mô tả cấu trúc thư mục, ví dụ: `images/`, `labels/`, `annotations.json`, và số lượng mẫu mỗi lớp.
- **OpenCV (tuỳ chọn):** có thể dùng để trích đặc trưng thủ công (SIFT, HOG, ORB, GLCM, LBP, v.v.) nhằm đối chiếu với hướng pretrained.

5 Cấu trúc nội dung thực hiện

Bài tập lớn được thực hiện dưới dạng `.ipynb`, chạy trực tiếp trên Google Colab. Mỗi loại dữ liệu được trình bày trong một file riêng biệt.

1. Mô tả tập dữ liệu:

- Sử dụng Markdown để mô tả thông tin tổng quan.
- Dùng Plotly, Matplotlib hoặc Seaborn để trực quan dữ liệu.

2. Chuẩn bị dữ liệu:

- Tiền xử lý bằng NumPy hoặc Pandas.
- Xử lý *missing values*, *outliers*, ...
- Encoding dữ liệu dạng *categorical*.
- Scaling dữ liệu dạng *numerical*.
- Chia dữ liệu thành **train**, **validation** và **test**.

3. Phân tích và mô hình hóa:

- Huấn luyện mô hình bằng Scikit-learn.
- So sánh kết quả giữa các mô hình hoặc tham số khác nhau.

4. Tổng kết và mở rộng:

- Đánh giá kết quả qua độ chính xác, biểu đồ, *confusion matrix*, ...
- Trình bày nhận xét, hạn chế và đề xuất hướng mở rộng.

6 Yêu cầu nộp bài

Định dạng và hình thức nộp

- Mỗi loại dữ liệu là một file `.ipynb` riêng.
- File phải **chạy hoàn chỉnh (Run all)** trên Google Colab mà không lỗi.
- Mỗi notebook cần có phần mô tả bằng **Markdown**, giải thích quy trình xử lý, biểu đồ và kết quả.

Video demo

- Giới thiệu quy trình và kết quả thực nghiệm.
- Thời lượng đề xuất: 5–10 phút.

Cách nộp bài

- Sinh viên/nhóm **chia sẻ link Colab** (với quyền chỉnh sửa) cho giảng viên và điền vào sheet "**SubmissionLinks**".
- Upload video demo lên YouTube (ở chế độ công khai hoặc unlisted) và điền link vào cùng sheet.

[Submission Links Sheet](#)

Hạn nộp

Báo cáo và video được trình bày trong buổi học cuối cùng của môn học.

7 Thang điểm đánh giá (Evaluation Rubric)

Thành phần đánh giá	Trọng số (%)
Chất lượng và hoàn thiện các notebook (.ipynb)	50
Báo cáo, giải thích, trình bày Markdown	20
Video demo và khả năng trình bày	15
Tính sáng tạo, mở rộng, tự động hóa	10
Hình thức nộp đúng quy định, link hợp lệ	5
Tổng cộng	100